

Домашнее задание по теме №3 по предмету “Обработка естественного языка” команды 10 (кейс 3)

0. Ссылки

Ссылка на git-репозиторий со всеми файлами:

https://github.com/ILKA777/NLP_TeamWork

Ноутбук по текущему ДЗ:

https://github.com/ILKA777/NLP_TeamWork/blob/main/NLP_2.ipynb или коллаб
<https://colab.research.google.com/drive/1Y7UPO8EfcW-yB9vdOZRIKDCZZNWk9tyu?usp=sharing>

Ссылка на датасет:

<https://www.kaggle.com/datasets/yutkin/corpus-of-russian-news-articles-from-lenta>

1. Задача и выбранные категории

Цель работы — разработать текстовый модуль, который определяет тему сообщения. В дальнейшем его планируется включить в систему классификации голосовых сообщений Telegram: сначала аудио преобразуется в текст, затем текстовому классификатору назначается тематическая метка.

В текущем эксперименте используются четыре категории:

- **Развлечения** — культурные события, кино, музыка и связанные материалы.
- **Спорт** — соревнования, спортсмены, команды и спортивные события.
- **Технологии** — научно-техническая, интернет- и медиатематика.
- **Новости** — общая общественно-политическая, экономическая и прочая новостная повестка.

Целевые метки формируются из исходных рубрик Lenta.ru по следующей схеме:

Категория	Исходные рубрики
Развлечения	Культура, Ценности, Культпросвет
Спорт	Спорт
Технологии	Наука и техника, Интернет и СМИ
Новости	Россия, Мир, Бывший СССР, Экономика, Бизнес, Силовые структуры, Из жизни, Дом, Путешествия, 69-я параллель, Крым

Такое объединение позволяет получить четыре крупных класса без ручной переразметки всего корпуса. При этом границы классов остаются приблизительными: например, рубрика «Интернет и СМИ» содержит не только технологические материалы, но и новости медиаповестки. Это учитывается при анализе ошибок.

2. Датасет и качество исходных данных

Для работы выбран Lenta.Ru-News-Dataset. Исследованный CSV содержит 800 975 записей и занимает около 2,08 ГБ. Каждая запись включает ссылку, заголовок, текст, рубрику, тег и дату. В корпусе представлены 24 непустые рубрики и 94 непустых тега. Средняя длина непустого текста составляет 1332,3 символа.

Файл полностью прочитан в UTF-8 без ошибок CSV-парсинга. Обнаружены пять пустых текстов, 1483 непустых текста короче 100 символов, семь текстов с возможными HTML-конструкциями и 937 повторных экземпляров текста после нормализации пробелов. Символ замены  не обнаружен.

Без учёта повторов 99,81335% записей не имеют выбранных автоматических признаков проблем. Это показатель технического контроля, а не доказанная доля содержательно чистых данных.

Дополнительно проведён ручной аудит 120 примеров: 100 записей без автоматических признаков и 20 с признаками. Первая группа признана пригодной. Во второй группе вместо полноценного текста встречались названия источников, перенаправления и короткие фрагменты. Объединять эти результаты в единый процент шума для всего корпуса нельзя, поскольку подозрительные записи специально включались в проверку в повышенной доле (manual_quality_audit.xlsx).

Качество транскрипций неприменимо: корпус содержит письменные статьи, а не расшифровки речи. Качество распознавания аудио будет оцениваться на последующем этапе.

3. Подготовка экспериментальной выборки

Из исходного корпуса отобраны записи 17 рубрик, используемых в целевой схеме. Получено 738 787 записей. Затем удалены 19 точных повторов по сочетанию заголовка и текста.

После объединения рубрик распределение было следующим:

Категория	Количество
Новости	514 662
Технологии	97 798
Спорт	64 411
Развлечения	61 897

Чтобы крупный класс общих новостей не доминировал, случайным образом выбрано по 30 000 примеров каждого класса. После предобработки и фильтрации коротких входов осталось 119 927 записей. Повторная проверка по очищенному тексту дополнительных дубликатов не обнаружила.

Данные разделены с сохранением распределения классов:

Часть	Количество	Приблизительная доля
Обучение	81 549	68%
Валидация	14 392	12%
Тест	23 986	20%

Для случайного отбора и разбиения использовано фиксированное значение `random_state = 42`. Тестовая выборка не используется для выбора гиперпараметров и весов ансамбля.

4. Метод предобработки

Мы реализовали функцию очистки и лемматизации текста. На вход подаётся заголовок вместе с текстом статьи; тематические теги и исходная рубрика не включаются в признаки.

Предобработка включает:

1. Ограничение входа первыми 1200 символами.
2. Удаление HTML-тегов, ссылок и адресов электронной почты.
3. Приведение к нижнему регистру и замену «ё» на «е».
4. Удаление цифр, пунктуации и символов вне русского и латинского алфавитов.
5. Нормализацию пробелов.
6. Лемматизацию через `pymorphy3`.
7. Удаление односимвольных токенов.

После обработки исключаются входы короче 60 символов. Из 120 000 отобранных записей этот фильтр исключил 73.

Лемматизация объединяет разные формы слова, а ограничение длины уменьшает затраты на обработку. Однако такая предобработка имеет ограничения: обрезка может потерять важную информацию в конце статьи, а удаление чисел — части названий устройств и другие значимые детали. Фильтр применяется к заголовку вместе с текстом и не гарантирует удаления всех записей без полноценного тела статьи.

5. Метод классификации и обоснование выбора

Использован подход из раздела «Наивные методы» вебинара 4: преобразование текста в числовые признаки и обучение обычного классификатора. В презентации этот подход рассматривается как базовое решение для классификации текста.

Признаковое представление объединяет два TF-IDF-векторизатора:

- Слова и словесные биграммы — до 200 000 признаков.
- Символьные n-граммы длиной 3–5 внутри границ слов — до 100 000 признаков.

В эксперименте получено 300 000 признаков. Словарь и IDF обучаются только на обучающей части; для валидации и теста используется уже обученное преобразование.

Сравнивались **LinearSVC** и **LogisticRegression**. Они выбраны как классические модели, работающие с разреженным текстовым представлением без трансформеров. Словесные признаки позволяют учитывать тематическую лексику и словосочетания, а символьные дополняют их фрагментами слов. Отдельный вклад каждой группы признаков в этой работе не измерялся.

Гиперпараметр **C** и тип основной модели выбирались по Macro F1 на валидации. Эта метрика используется, чтобы учитывать качество каждого из четырёх классов с одинаковым весом.

6. Результаты классификации

На валидации получены следующие лучшие результаты:

Модель	Лучший C	Validation Macro F1
LinearSVC	0,3	0,9388
LogisticRegression	3,0	0,9361

Основной моделью выбран LinearSVC. На тестовой выборке:

Метрика	Значение
Accuracy	0,9399
Macro F1	0,9398
Weighted F1	0,9399

Результаты по классам, округлённые в `classification_report`:

Класс	Precision	Recall	F1
Новости	0,91	0,91	0,91
Развлечения	0,95	0,96	0,95
Спорт	0,99	0,99	0,99
Технологии	0,92	0,91	0,91

Лучше всего распознаётся спорт. Наиболее сложными оказались общие новости и технологии. Все значения относятся к подготовленной, почти сбалансированной выборке Lenta.ru, а не к реальным сообщениям Telegram.

7. Эксперимент с ансамблем

Дополнительно исследован ансамбль LinearSVC и LogisticRegression. Оценки SVM нормировались через softmax и смешивались с вероятностями логистической регрессии. Веса выбирались перебором на валидационной выборке.

Лучшие ненормированные веса — $(0, 2; 0)$. После нормализации это соответствует использованию только SVM. Validation Macro F1 остался равным 0,9388, поэтому улучшения от ансамбля не получено. Финальным решением оставлена одиночная модель LinearSVC.

Таким образом, эксперимент с подбором весов выполнен, но совместное использование двух моделей в данном запуске не оказалось полезнее лучшей одиночной модели.

8. Анализ ошибок

Основная модель ошиблась в 1441 из 23 986 тестовых примеров — 6,01%.
Самые частые смешения:

Пара классов, оба направления	Количество ошибок
Новости ↔ Технологии	749
Новости ↔ Развлечения	281
Технологии ↔ Развлечения	248
Новости ↔ Спорт	75

Около 52% всех ошибок приходится на пару «Новости / Технологии».

Просмотр примеров показывает несколько причин:

- Пересечение тем. Материал о строительстве корабля размечен как общие новости, но содержит выраженную техническую лексику.
- Широкое объединение рубрик. Сюжет о политическом репортаже телеканала относится к технологиям из-за исходной медиарубрики, хотя по содержанию близок к общим новостям.
- Пограничные материалы. Новость об утечке книги в интернет сочетает культурную и интернет-тематику.
- Различие между редакционной рубрикой и основной темой текста. Новости об уголовных делах с участием футболистов могут восприниматься как общие новости, несмотря на спортивную рубрику.

Поэтому часть расхождений связана не только с моделью, но и с принятым способом формирования целевых меток. Для улучшения решения полезно уточнить границы классов и вручную проверить пограничные примеры.

9. Итог и дальнейшая работа

Мы реализовали предобработку и тематическую классификацию текста без трансформеров. Лучший вариант — TF-IDF-признаки слов и символов с LinearSVC — показал Ассигасу 93,99% и Macro F1 0,9398 на отложенной тестовой выборке. Ансамбль с весами, подобранными на валидации, не улучшил результат.

Следующие направления работы — уточнение тематической разметки, проверка на реальных текстовых сообщениях Telegram и оценка влияния предобработки.

Для перехода к аудиосообщениям планируется использовать Golos и русский раздел Common Voice для оценки и возможной адаптации распознавания речи. Подготовленные тематические тексты также предполагается озвучивать через TTS. Качество аудиопайплайна будет проверяться отдельно от качества текстового классификатора.