

Техническое описание датасетов

Кейс №3. Тематическая классификация новостей (аудиосообщения Telegram)

1. Описание кейса

Название кейса: Тематическая классификация новостей — классификация новостей по темам (развлечения, спорт, технологии и т.п.).

Краткое описание: необходимо создать систему, классифицирующую аудио-сообщения из Telegram по заранее определённым категориям тематики.

Категории классификации:

- Развлечения — сообщения, связанные с культурными событиями, фильмами, музыкой и т.д.
- Образование — сообщения, касающиеся учебных материалов, курсов, лекций и т.д.
- Технологии — сообщения, обсуждающие новинки в области технологий, гаджетов и т.д.

Описание системы: на вход подаются голосовые сообщения, на выход — метка тематики.

Усложнение задачи: использовать TTS (Text-to-Speech) для синтеза аудио с различными тематиками на основе текстовых данных, чтобы обогатить тренировочный датасет.

2. Постановка задачи для подбора данных

Готового датасета «голосовое сообщение Telegram + метка темы» в открытом доступе не существует. Поэтому ниже отобраны 3 датасета, закрывающие все звенья пайплайна: (1) аудио для обучения распознавания речи, (2) тексты с готовой тематической разметкой, которые далее озвучиваются через TTS согласно условию усложнения задачи, и (3) дополнительный источник разнообразных голосов.

3. Датасеты

3.1 Golos (SberDevices) — аудиокорпус

Объём: ≈1240 часов, более 1 млн коротких аудиозаписей и транскрипций, 16 кГц.

Структура: пары «аудиофайл — текстовая транскрипция»; домены Crowd (краудсорсинг) и Farfield (удалённый микрофон).

Качество разметки: ручная, с перекрытием — несколько разметчиков на запись, высокая достоверность.

Лицензия: открытая, близкая к CC BY-SA — исследовательское и коммерческое использование.

Применимость: основа для обучения/адаптации модуля распознавания речи (ASR), переводящего голосовое сообщение в текст перед классификацией темы.

Ссылка: <https://github.com/sberdevices/golos>

3.2 Lenta.Ru-News-Dataset — текст с темой

Объём: ≈800 975 новостных статей, ≈2 Гб текста.

Структура: поля url, title, text, topic, tags — готовая тематическая метка, проставленная редакцией (Россия, Мир, Культура, Наука и техника, Экономика, Спорт и т.д.).

Качество разметки: редакционная разметка — высокая надёжность, но категории нужно перемасштабировать на целевую схему тем проекта (развлечения/образование/технологии).

Лицензия: открытый парсинг публичных страниц, для исследовательских целей.

Применимость: главный источник тематически размеченных текстов; согласно условию усложнения задачи, эти тексты озвучиваются через TTS, формируя обучающую выборку «аудио → тема».

Ссылка: <https://github.com/yutkin/Lenta.Ru-News-Dataset>

3.3 Mozilla Common Voice (русский раздел) — разнообразие голосов

Объём: ≈3300 часов русской речи (пополняемый датасет).

Структура: короткие фразы волонтеров с транскрипцией; частично — метаданные о возрасте, поле, акценте.

Качество разметки: краудсорсинговая валидация несколькими участниками; есть доля неподтверждённых клипов — требуется фильтрация по полю validated.

Лицензия: CC0 (общественное достояние) — без ограничений на использование.

Применимость: повышает устойчивость модели к разным голосам и акцентам, компенсируя однообразие синтетической TTS-речи из п. 3.2.

Ссылка: <https://commonvoice.mozilla.org/ru>

4. Сводная таблица

Датасет	Тип данных	Объём	Роль в проекте
Golos	Аудио + транскрипция	1240 ч / 1 млн записей	Обучение ASR-модуля
Lenta.Ru-News-Dataset	Текст + метка темы	≈800 тыс. статей	Источник тем для TTS-аугментации
Common Voice (RU)	Аудио + транскрипция	≈3300 ч	Разнообразие голосов/акцентов

5. Вывод

Отобранные три датасета совместно закрывают требуемый пайплайн: Golos и Common Voice дают речевую базу для распознавания голосовых сообщений, а Lenta.Ru-News-Dataset — тексты с готовой тематической разметкой. В соответствии с условием усложнения задачи, эти тексты синтезируются в аудио (например, с помощью TTS-модели Silero), что позволяет получить обучающий набор «аудио → тема» без необходимости вручную размечать реальные голосовые сообщения.